

On Exploring Undetermined Relationships for Visual Relationship Detection

视觉关系检测中不确定关系的探索 (CVPR-2019)

<https://github.com/Atmegal/MFURLN-CVPR-2019-relationship-detection-method>


【任务】视觉关系检测

【数据集】VRD、VG

【动机/贡献点】大量的关系未被标注 ==> 利用不确定的关系，改善视觉关系检测的性能

(1) 确定关系：人类标记的关系


(2) 不确定关系：未标记对象对构成的其他关系（具有关系但未被人类标记的对象对、没有关系的对象对、具有错误检测结果的物体对）



不确定关系可以视作对确定关系的补充？包含否定样本以及人们的不喜欢的偏好(包括不太重要的未标记的关系及异常的表达，如杯子在桌子上)

【方法】提出了一种基于多模式特征的不确定关系学习网络 (MF-URLN)，来自动生成有用的不确定关系。

- (1) 使用检测器检测出对象，组成对象对
- (2) 使用设计的标准将该对象对与人类标记的关系进行比较
- (3) 提取并融合视觉、空间和语义模态的特征
- (4) 使用置信度子网络+关系预测子网络，生成不确定关系



$$P(R) = P(p|s, o, d)P(d|s, o)P(s|B_s)P(o|B_o)$$

其中 s, p, o, d, R 分别代表主语、谓词、宾语、置信度和关系

检测：Faster R-CNN + VGG-16，给出 $P(s|B_s)$ 和 $P(o|B_o)$ ，保留概率大于 0.05 的检测对象

确定关系的标准：主语和宾语的类别与标注一致，且 IoU 均大于 0.5

MF-URLN 的不确定关系学习网络包括两部分：多模态特征提取网络和关系学习网络

(一) 多模态特征提取网络：视觉特征+空间特征+语义特征

- (1) 视觉特征：主语和宾语分别的边界框，边界框的并集
- (2) 空间特征：利用三组边界框

$(x_{min}^s, y_{min}^s, x_{max}^s, y_{max}^s)$ 、 $(x_{min}^o, y_{min}^o, x_{max}^o, y_{max}^o)$ 和 $(x_{min}^u, y_{min}^u, x_{max}^u, y_{max}^u)$

$$\left[\frac{x_{min}^s - x_{min}^u}{x_{max}^u - x_{min}^u}, \frac{y_{min}^s - y_{min}^u}{y_{max}^u - y_{min}^u}, \frac{x_{max}^s - x_{max}^u}{x_{max}^u - x_{min}^u}, \frac{y_{max}^s - y_{max}^u}{y_{max}^u - y_{min}^u}, \right. \\ \left. \frac{x_{min}^o - x_{min}^u}{x_{max}^u - x_{min}^u}, \frac{y_{min}^o - y_{min}^u}{y_{max}^u - y_{min}^u}, \frac{x_{max}^o - x_{max}^u}{x_{max}^u - x_{min}^u}, \frac{y_{max}^o - y_{max}^u}{y_{max}^u - y_{min}^u} \right]$$

分别表示主语和宾语两个对象相对于整个并集框的位置

- (3) 语义特征：外部+内部

外部：Wikipedia 2014 上预训练 word2vec (噪声可能较大)

内部：朴素贝叶斯+拉普拉斯平滑 (为了适应 zero-shot)，对训练集所有的关系三元组频率进行统计，转换为主语和宾语的概率分布

- (4) 特征融合：

由于高维特征 (例如 4096 维视觉特征) 会轻易淹没低维特征 (例如 8 维空间特征)，因此先将特征转换为相同的维度，然后再进行多模态特征的融合。

(二) 关系学习网络：置信度子网络+关系预测子网络

- (1) 置信度子网络

确定对象对的确定置信度，反映了对象对被人工选择和标注的可能性 (即具有确定关系的概率)

$$\text{CE}(p, y) = \begin{cases} -\log(p) & \text{if } y = 1 \\ -\log(1 - p) & \text{otherwise.} \end{cases}$$

交叉熵损失：

使用上标 d 和 i 表示确定和不确定的关系，确定的关系 $y=1$ ，不确定的关系 $y=0$

对于确定的关系， $L_{det}^d = \text{CE}(P(d^d|s^d, o^d), 1)$

对于不确定的关系， $L_{det}^i = \text{CE}(P(d^i|s^i, o^i), 0)$

总的置信度损失函数： $L_{det} = L_{det}^d + \alpha L_{det}^i$, (文中 $\alpha=1$, 认为两者同等重要)

- (2) 关系预测子网络

确定的关系： $L_{rel}^d = \sum_{k=1}^M \text{CE}(P(p_k^d|s^d, o^d, d^d), y_k)$ 第 k 个谓词， M 是谓词的数量

不确定的关系，视为没有谓词： $L_{rel}^i = \sum_{k=1}^M \text{CE}(P(p_k^i|s^i, o^i, d^i), 0).$

*当前没有可靠的方法来自动标记这些不确定的关系

总的关系预测损失函数： $L_{rel} = L_{rel}^d + \lambda_1 L_{rel}^i.$

\Rightarrow 联合损失函数： $L = L_{rel} + \lambda_2 L_{det}. \Rightarrow L = L_{rel}^d + \lambda_1 L_{rel}^i + \lambda_2 L_{det}^d + \lambda_2 L_{det}^i.$

【实验】

数据集: VRD (5000 张图像, 100 个对象类型, 70 个谓词; 3700 训练+300 验证+1000 测试, 1169 个关系三元组只出现在测试集)、VG (划分: 99652 张图像, 200 个对象类别, 100 个谓词; 68794 训练+5000 验证+25858 测试)

任务: 谓词检测, 短语检测和关系检测

指标: Recall @ N (R_N)

Table 1. Performance comparison of visual relationship detection methods on the VRD dataset. Pre., Phr., and Rel. represent predication detection, phrase detection, and relation detection, respectively. “-” denotes that the result is unavailable.

	Pre. $R_{50/100}$	Phr.		Rel.	
		R_{50}	R_{100}	R_{50}	R_{100}
语义知识	VRD-Full [23]	47.9	16.2	17.0	13.9
端到端网络	VTransE [37]	44.8	19.4	22.4	14.1
端到端网络	VIP-CNN [20]	-	22.8	27.9	17.3
其它方法	Weak-S [26]	52.6	17.9	19.5	15.8
其它方法	PPRFCN [38]	47.4	19.6	23.2	14.4
语义知识	LKD:S [34]	47.5	19.2	20.0	16.6
语义知识	LKD:T [34]	54.1	22.5	23.6	18.6
语义知识	LKD:S+T [34]	55.2	23.1	24.0	19.2
端到端网络	DVSRL [22]	-	21.4	22.6	18.2
端到端网络	TFR [15]	52.3	17.4	19.1	15.2
深度结构学习	DSL [41]	-	22.7	24.0	17.4
其它方法	STA [32]	48.0	-	-	-
其它方法	Zoom-Net [33]	50.7	24.8	28.1	18.9
其它方法	CAI+SCA-M [33]	56.0	25.2	28.9	19.5
其它方法	VSA [12]	49.2	19.1	21.7	16.0
MF-URLN		58.2	31.5	36.1	23.9
					26.8

Table 2. Performance comparison of six methods on the VG dataset. “-” denotes that the result is unavailable.

	Pre.		Phr.		Rel.	
	R_{50}	R_{100}	R_{50}	R_{100}	R_{50}	R_{100}
VTransE [37]	62.6	62.9	9.5	10.5	5.5	6.0
PPRFCN [38]	64.2	64.9	10.6	11.1	6.0	6.9
DSL [41]	-	-	13.1	15.6	6.8	8.0
STA [32]	62.7	62.9	-	-	-	-
VSA [12]	64.4	64.5	9.7	10.0	6.0	6.3
MF-URLN	71.9	72.2	26.6	32.1	14.4	16.5

Table 3. Performance comparison on the zero-shot set of the VRD dataset. “-” denotes that the result is unavailable.

	Pre.	Phr.	Rel.		
	$R_{50/100}$	R_{50}	R_{100}	R_{50}	R_{100}
VRD-Full [23]	12.3	5.1	5.7	4.8	5.4
VTransE [37]	-	2.7	3.5	1.7	2.1
Weak-S [26]	21.6	6.8	7.8	6.4	7.4
LKD:S [34]	17.0	10.4	10.9	8.9	9.1
LKD:T [34]	8.8	6.5	6.7	6.1	6.4
DVSRL [22]	-	9.2	10.3	7.9	8.5
TFR [15]	17.3	5.8	7.1	5.3	6.5
STA [32]	20.6	-	-	-	-
MF-URLN	26.9	5.9	7.9	4.3	5.5
MF-URLN-IM	27.2	6.2	9.2	4.5	6.4

Zero-shot 效果不好：一些 unseen 的确定关系被错误地分类为不确定，仍然需要更好的策略来产生和利用不确定的关系

消融实验：V 视觉，S 空间， $L_{ex,in}$ 外部和内部语义

Table 4. R_{50} predicate detection and relation detection of the MF-URLN and its eight variants on the VRD dataset.

	Transforming		Concatenating	
	Pre.	Rel.	Pre.	Rel.
Baseline: V	52.29	22.64	53.01	22.85
Baseline: $L_{ex,in}$	53.39	18.49	53.94	18.07
Baseline: S	43.43	17.94	43.44	17.95
$V+S$	54.66	23.15	52.36	22.75
$V+L_{ex,in}$	57.27	23.21	55.45	22.62
$L_{ex,in}+S$	57.10	23.67	56.04	23.29
$V+S+L_{in}$	56.87	23.15	53.25	22.51
$V+S+L_{ex}$	57.69	23.50	55.29	22.83
MF-URLN	58.22	23.89	55.77	22.61

需要考虑更好的多特征融合策略

